

Sessió 10

Yimin Pan, Santi Otín

Llegir les imatges

```
clc; clear;

erableNames = dir('Erable\*.jpg');
faigNames = dir('Faig\*.jpg');
roureNames = dir('Roure\*.jpg');
for i=1:length(erableNames)
    erableImgs{i} = imread(fullfile(erableNames(i).folder, '\', erableNames(i).name));
    faigImgs{i} = imread(fullfile(faigNames(i).folder, '\', faigNames(i).name));
    roureImgs{i} = imread(fullfile(roureNames(i).folder, '\', roureNames(i).name));
end
```

Descriptors de Fourier

```
Labels = []; % Tags de les imatges
FD = []; % Feature Matrix (Fourier Descriptor)
N = 25; % Nombre de descriptors
resize = 1/16;

for i=1:length(erableImgs)
    im = erableImgs{i};
    im=imresize(im,resize);
    im = im2bw(im);
    im = ~im;
    %Extreure contorn
    ero=imerode(im,strel('disk',1));
    cont=xor(ero,im);
    [fila col] = find(im,1);
    B = bwtraceboundary(im,[fila col], 'E');
    aux=zeros(size(im));
    %Calcular descriptor de Fourier
    mig=mean(B);
    B(:,1)=B(:,1)-mig(1);
    B(:,2)=B(:,2)-mig(2);
    s= B(:,1) + 1i*B(:,2);
    [mida,~]=size(B);
    if(mida/2~=round(mida/2))
        s(end+1,:)=s(end,:);
        mida=mida+1;
    end
    %Les imatges tenen diferent mida, per tant el nombre de descriptors
    %resultant també serà diferent. Pero podem forçar un mateix nombre per
    %tots
    z=fft(s, N);
    % Convertir el complex com 2 features (real e imaginari) ja que el
    % learner no es compatible amb els complexos
    z2 = [real(z) imag(z)];
    z2 = reshape(z2.',1,[]);
```

```

    FD = [FD; z2];
    Labels = [Labels; "erable"];

end

% Mateix proces per les altre tipus de fulles
for i=1:length(faigImgs)
    im = faigImgs{i};
    im=imresize(im,resize);
    im = im2bw(im);
    im = ~im;
    %Extreure contorn
    ero=imerode(im,strel('disk',1));
    cont=xor(ero,im);
    [fila col] = find(im,1);
    B = bwtraceboundary(im,[fila col],'E');
    aux=zeros(size(im));
    %Calcular descriptor de Fourier
    mig=mean(B);
    B(:,1)=B(:,1)-mig(1);
    B(:,2)=B(:,2)-mig(2);
    s= B(:,1) + 1i*B(:,2);
    [mida,~]=size(B);
    if(mida/2~=round(mida/2))
        s(end+1,:)=s(end,:);
        mida=mida+1;
    end
    z=fft(s, N);
    z2 = [real(z) imag(z)];
    z2 = reshape(z2.',1,[]);
    FD = [FD; z2];
    Labels = [Labels; "faig"];
end

for i=1:length(roureImgs)
    im = roureImgs{i};
    im=imresize(im,resize);
    im = im2bw(im);
    im = ~im;
    %Extreure contorn
    ero=imerode(im,strel('disk',1));
    cont=xor(ero,im);
    [fila col] = find(im,1);
    B = bwtraceboundary(im,[fila col],'E');
    aux=zeros(size(im));
    %Calcular descriptor de Fourier
    mig=mean(B);
    B(:,1)=B(:,1)-mig(1);
    B(:,2)=B(:,2)-mig(2);
    s= B(:,1) + 1i*B(:,2);
    [mida,~]=size(B);
    if(mida/2~=round(mida/2))
        s(end+1,:)=s(end,:);

```

```

        mida=mida+1;
    end
    z=fft(s, N);
    z2 = [real(z) imag(z)];
    z2 = reshape(z2.',1,[]);
    FD = [FD; z2];
    Labels = [Labels; "roure"];
end

T = array2table(FD);
T = addvars(T, Labels, 'Before',1);

```

Feature Vector

El vector de característiques és el descriptor de Fourier del contorn de la imatge corresponent, amb N com el nombre de descriptors. Llavors la mida d'aquest vector es 2N, ja que hem separat cada descriptor complex en part imaginària i real, la raó és que el "Classification Learner" no és capaç de tractar els complexos.

Experiment i Resultat

Donat que les mostres estan bastant bé equilibrats (1/3 de cada tipus de fulla), la precisió és un bon indicador del rendiment del classificador. Per tant no farà falta servir altres indicadors com f-score.

Per evitar overfitting i evitar resultar en una falsa precisió alta, tots els processos de validació es faran amb cross-validation (5-folds).

S'han fet experiments amb diferents nombres de descriptors (N). Una altra manera de fer-ho és deixar un N suficientment gran i després en la part de Feature Selection seleccionar els que volem testejar però degut al alt nombre de descriptors aquesta forma no és molt viable.

- N = 25: precisió del 93.8% per les Arbres de decisió, 79.5% per Naive Bayes i 95.8% pels mètodes ensamblats.
- N = 50: precisió del 87.5% per les Arbres de decisió, 79.5% per Naive Bayes i 95.8% pels mètodes ensamblats.
- N = 150: precisió del 81.3% per les Arbres de decisió, 87.5% per Naive Bayes i 91.7% pels mètodes ensamblats.
- N = 250: precisió del 75% per les Arbres de decisió, 80% per Naive Bayes i 91% pels mètodes ensamblats.
- N = 500: precisió del 79.2% per les Arbres de decisió, 81.3% per Naive Bayes i 89% pels mètodes ensamblats.
- N = 750: precisió del 68.8% per les Arbres de decisió, 85.4% per Naive Bayes i 89.6% pels mètodes ensamblats.

En la sessió anterior hem après que quan més descriptors tenim, la imatge és més detallada. Però en aquest experiment podem veure que més no és millor, la raó és que en machine learning existeix el que es diu "curse of dimensionality". Quan tenim un nombre molt alt de features (200, 500 ...), l'espai de característiques es torna molt dispers i això es molt problemàtic pels mètodes que requereixen estadística. La solució seria augmentar el nombre de samples, però en aquest cas no es possible, per a que podem veure que classificadors amb menys descriptors (N) sol tenim una millor rendiment.

A més quan la dimensionalitat augmenta, es requereix més temps d'entrenament.

Per tant, el millor resultat s'obté amb entre 25 i 50 descriptors, amb 95.8% de precisió amb Bagged Tree. I aquest es la matriu de confusió:

Model 1.21

True class	erable		
	faig		
	roure		
	erable	faig	roure
	16	15	1
		1	15

solament hem tingut 2 errors de classificació.